UT5. Recurrent Neural Networks (RNN).

IES Abastos

CE Inteligencia Artificial y Big Data
Sistemas de Aprendizaje Automático.

Bloques de la unidad:

1. Entrenamiento Recurrent Neural Networks.
2. Modelos del lenguaje con RNNs.
3. Laboratorio 5 - Optimización word vectors
4. Arquitecturas LSTM y GRU.
5. Laboratorio 6 -Comparativa clasificación de textos.
6. Laboratorio 7 -Comparativa regresión.

1. Entrenamiento Recurrent Neural Networks.

Tratan problemas sobre **secuencias**.

¿ **Parámetros** ?

¿ **Hiperparámetros** ?

¿ **Arquitecturas** ?

1. Entrenamiento Recurrent Neural Networks.

Hasta ahora, hemos visto dos tipos de redes neuronales: feed-forward y CNNs. En ambas, tenemos un input de tamaño fijo (por ejemplo, una imagen) y una única salida.

En muchos problemas de machine learning nos gustaría tener más flexibilidad, con arquitecturas que tengan una longitud variable de inputs y de outputs.

Por ejemplo: representación **bag-of-words** de un texto vs **secuencia de palabras.**

1. Entrenamiento Recurrent Neural Networks.

Las Recurrent Neural Networks (RNNs), o redes neuronales recurrentes, son un tipo de red neuronal capaz de trabajar con información secuencial.

Mantienen un **estado interno o hidden state,** que podemos considerar como una memoria de lo visto hasta el momento.

Aplican una **fórmula recurrente** sobre una secuencia de entrada de manera que, en cada paso de la secuencia, se depende del valor de input x de ese momento y del hidden state anterior h.

1. Entrenamiento Recurrent Neural Networks.

Cada paso en la secuencia se conoce como **time step.**

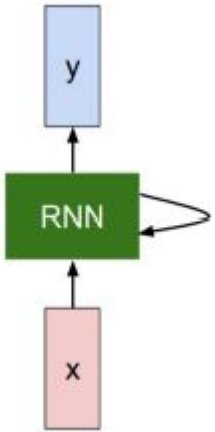

1. Entrenamiento Recurrent Neural Networks.

La potencia de las RNNs radica en su capacidad de modelar relaciones temporales entre elementos de la secuencia a través del estado interno de la red.

Esto explica por qué este tipo de arquitectura ha tenido gran éxito en problemas de lenguaje natural, donde el contexto y el orden son determinantes.

Las redes recurrentes son muy versátiles y pueden aplicarse a varios tipos de problema según queramos secuencias de entrada y/o de salida.

1. Entrenamiento Recurrent Neural Networks.

Secuencia a salida única.

Input: Secuencia

Output: Único output al final de la secuencia.

Ejemplo: Análisis de sentimiento de una oración o texto

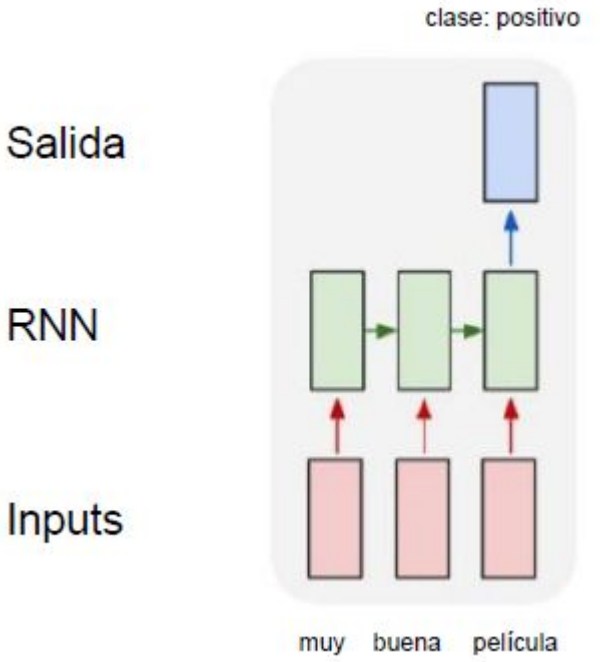

1. Entrenamiento Recurrent Neural Networks.

Secuencia a secuencia.

Input: Secuencia

Output: Secuencia con un valor de salida por cada elemento de entrada.

Ejemplo: Clasificación de imágenes frame a frame en un vídeo.

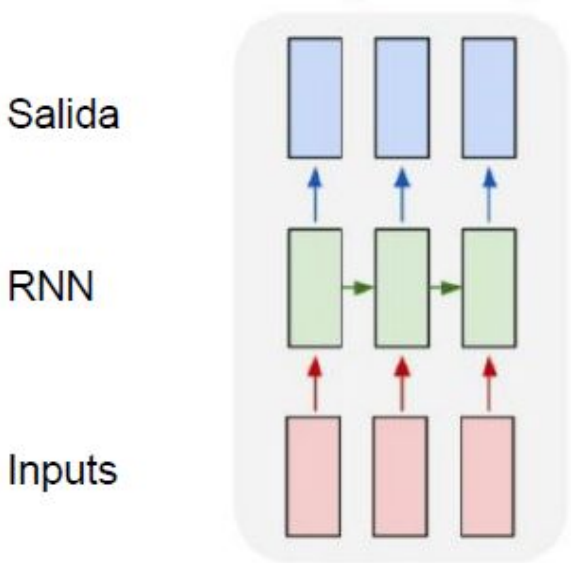

1. Entrenamiento Recurrent Neural Networks.

Secuencia a secuencia (seq2seq)

Input: Secuencia

Output: Secuencia. Se espera a leer toda la secuencia de entrada antes de generar la secuencia de salida.

Ejemplo: Machine translation.

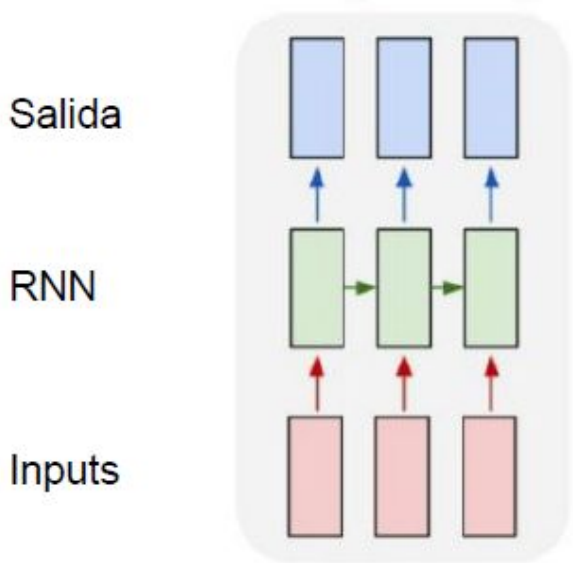

1. Entrenamiento Recurrent Neural Networks.

Input único a secuencia (seq2seq)

Input: Elemento único

Output: Secuencia.

Ejemplo: Image captioning.

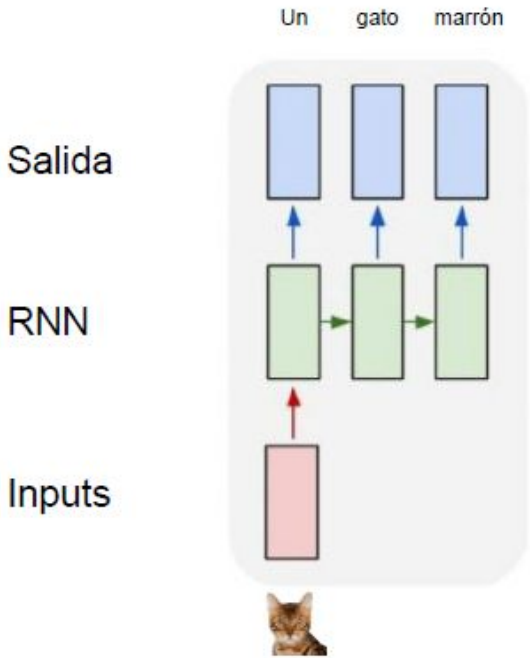

1. Entrenamiento Recurrent Neural Networks.

RNN: Toma una secuencia de valores de entrada y, de manera recurrente, aplica una transformación a partir de cada valor de entrada y del hidden state que posee la red en ese momento. Obteniendo:

- Nuevo estado interno
- (Opcional) Nuevo valor de salida

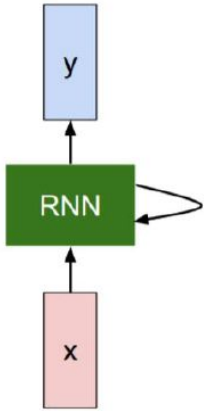

1. Entrenamiento Recurrent Neural Networks.

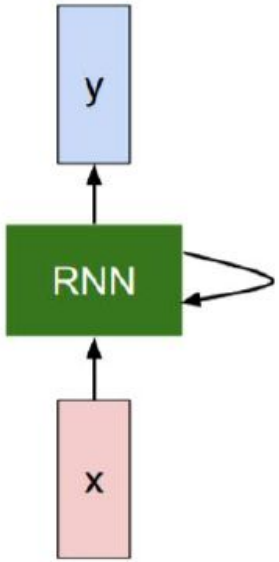

$$h_t = f_W(h_{t-1}, x_t)$$

Función de recurrencia de una RNN

- h_t - (vector) hidden state en tiempo *t*. Su dimensión es un hiperparámetro.
- f_W - transformación no lineal con W los parámetros o weights de la RNN.
- x_t - (vector) input en tiempo *t*.

Fuente de la imagen: Stanford CS231N

tico.

1. Entrenamiento Recurrent Neural Networks.

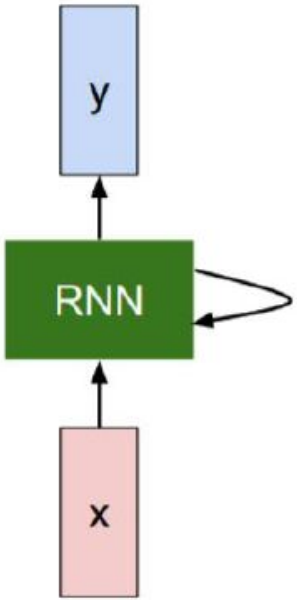

$$h_t = f_W(h_{t-1}, x_t)$$

Ecuaciones para una Vanilla RNN (RNN sencilla):

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

$$y_t = W_{hy}h_t$$

W_{hh}, W_{xh}, W_{hy} matrices de parámetros

Fuente de la imagen: Stanford CS231N

1. Entrenamiento Recurrent Neural Networks.

"Desenrollando" RNNs

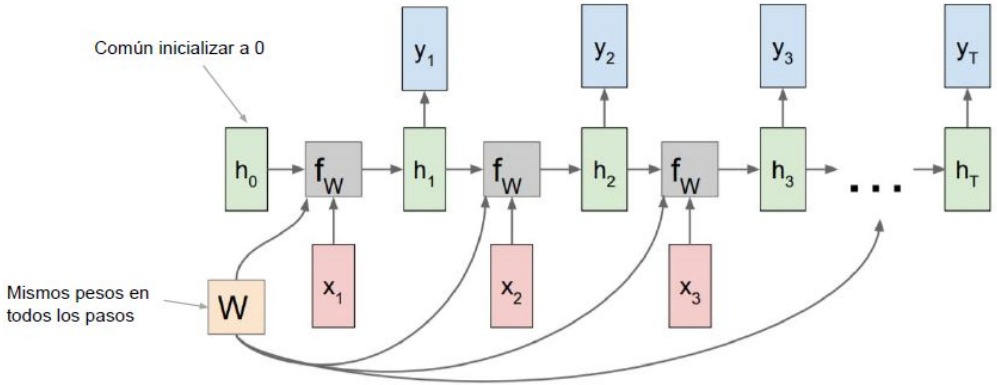

Función de recurrencia:

$$h_t = f_W(h_{t-1}, x_t)$$

Ecuaciones para una Vanilla RNN:

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

$$y_t = W_{hy}h_t$$

W_{hh}, W_{xh}, W_{hy} matrices de parámetros

Fuente de la imagen: Stanford CS231N

1. Entrenamiento Recurrent Neural Networks.

"Desenrollando" RNNs

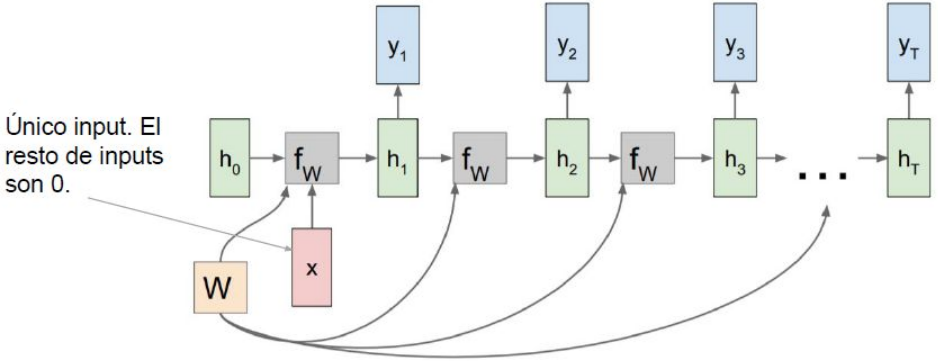

Función de recurrencia:

$$h_t = f_W(h_{t-1}, x_t)$$

Ecuaciones para una Vanilla RNN:

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

$$y_t = W_{hy}h_t$$

W_{hh}, W_{xh}, W_{hy} matrices de parámetros

Fuente de la imagen: Stanford CS231N

1. Entrenamiento Recurrent Neural Networks.

“Desenrollando” RNNs: Es necesario “desenrollar” el grafo de computación a lo largo del tiempo y aplicar backpropagation a partir de todos los outputs que hemos obtenido.

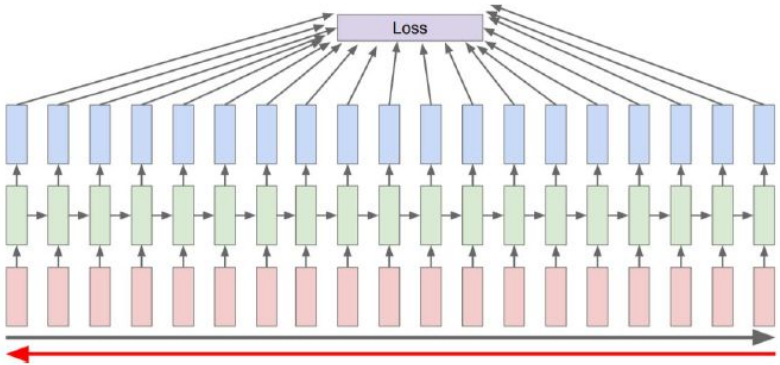

1. Entrenamiento Recurrent Neural Networks.

Backpropagation through time (BPTT):

- Se hace forward pass a lo largo de toda la secuencia para calcular la loss a partir de todos los outputs.
- Se hace backward pass a lo largo de toda la secuencia.

1. Entrenamiento Recurrent Neural Networks.

BPTT es muy costoso para secuencias largas.
En la práctica, se utiliza Truncated Backpropagation through time.
La secuencia se parte en trozos y se hace backpropagation en un pequeño número de steps, trozo a trozo.

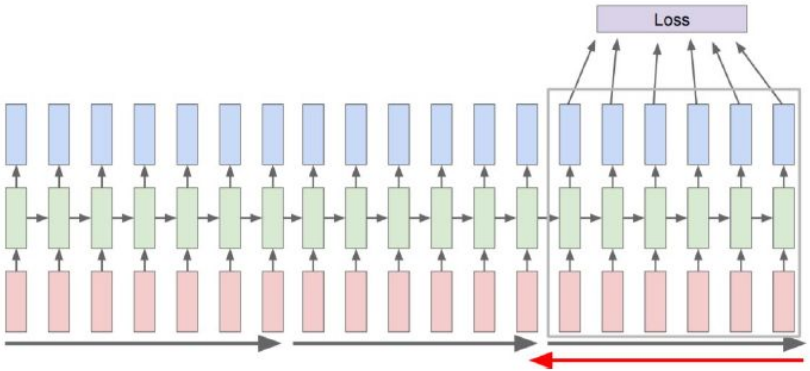

2. Modelos del lenguaje con RNNs

Los modelos del lenguaje, o language models, son una aplicación de las redes recurrentes donde éstas han conseguido muy buenos resultados.
Un modelo del lenguaje es un modelo que asigna una probabilidad a una secuencia de palabras (o de caracteres).

$$p(w_1, w_2, \dots, w_T)$$

2. Modelos del lenguaje con RNNs

Estos modelos son muy útiles. Por ejemplo, en traducción automática se puede tener una serie de traducciones candidatas, con lo que podemos valernos de la probabilidad según el modelo para elegir la mejor traducción.

$$p(\text{“la casa es pequeña”}) > p(\text{“pequeña la casa es”})$$

2. Modelos del lenguaje con RNNs

2. Modelos del lenguaje con RNNs

Normalmente se calculan las probabilidades condicionando la probabilidad de que cada palabra aparezca después de las palabras anteriores. Se asume independencia y se aproxima a sólo unas pocas palabras anteriores:

$$P(w_1, \dots, w_m) = \prod_{i=1}^{m} P(w_i | w_1, \dots, w_{i-1}) \approx \prod_{i=1}^{m} P\left(w_i | w_{i-(n-1)}, \dots, w_{i-1}\right)$$

2. Modelos del lenguaje con RNNs

Las probabilidades se estiman contando en el texto cuántas veces aparecen las palabras juntas.

$$p(w_2|w_1) = \frac{\text{count}(w_1, w_2)}{\text{count}(w_1)} \qquad p(w_3|w_1, w_2) = \frac{\text{count}(w_1, w_2, w_3)}{\text{count}(w_1, w_2)}$$

Este modelo sencillo es muy útil y funciona correctamente. Sin embargo, para alcanzar buenas calidades se hace computacionalmente muy costoso.

2. Modelos del lenguaje con RNNs

- Un modelo del lenguaje puede tratarse de manera natural con recurrent neural networks.
- Podemos suministrar una secuencia de palabras a nuestra red recurrente, de manera que la red nos dé una distribución de probabilidad de la palabra siguiente.
- El hidden state de la RNN codifica en cierta medida el texto visto hasta ahora, por lo que la red es capaz de condicionar la probabilidad de la siguiente palabra a lo visto anteriormente.

2. Modelos del lenguaje con RNNs

- El input de cada time step puede ser un word vector o una representación one-hot.
- La salida en cada time step viene dada por una capa softmax con las probabilidades de que cada palabra del vocabulario sea la siguiente en la secuencia.

2. Modelos del lenguaje con RNNs

Ejemplo: Modelo del lenguaje con caracteres.
Vocabulario de 4 caracteres: [h, e, l, o]
Input: Representaciones one-hot

- h: [1,0,0,0]
- e: [0,1,0,0]
- l: [0,0,1,0]
- o: [0,0,0,1]

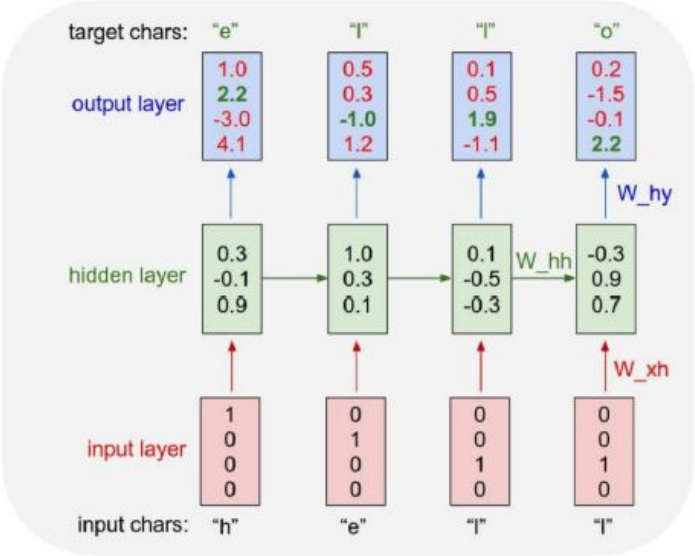

2. Modelos del lenguaje con RNNs

Ejemplo: Modelo del lenguaje con caracteres.
Vocabulario de 4 caracteres: [h, e, l, o]
Input: softmax sobre los 4 posibles caracteres.

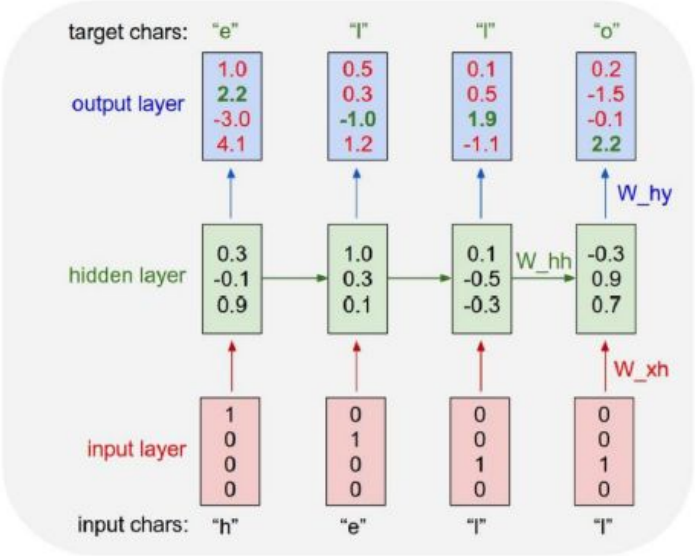

2. Modelos del lenguaje con RNNs

Ejemplo: Modelo del lenguaje con caracteres.
Vocabulario de 4 caracteres: [h, e, l, o]
Entrenamiento: Secuencias de texto.
Se intenta predecir el siguiente carácter.

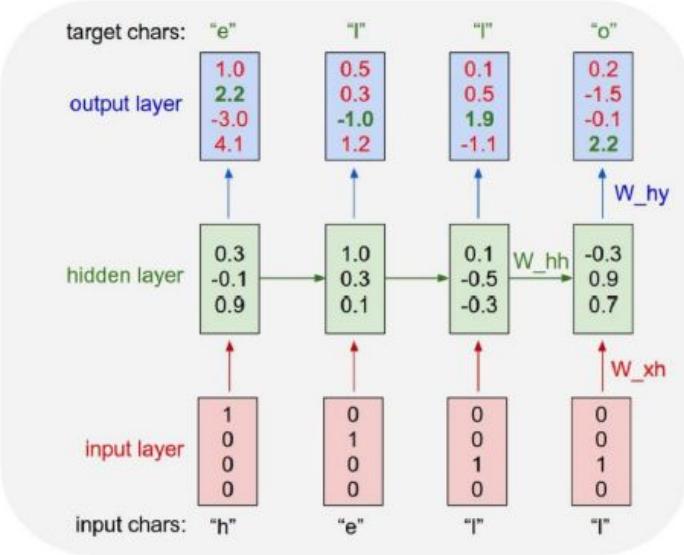

2. Modelos del lenguaje con RNNs

Input layer dim: 4
Hidden layer dim: 3
Output layer dim: 4

$$h_t = \tanh(W_{hh} h_{t-1} + W_{xh} x_t)$$

$$y_t = W_{hy} h_t$$

W_{hh}, W_{xh}, W_{hy} matrices de parámetros

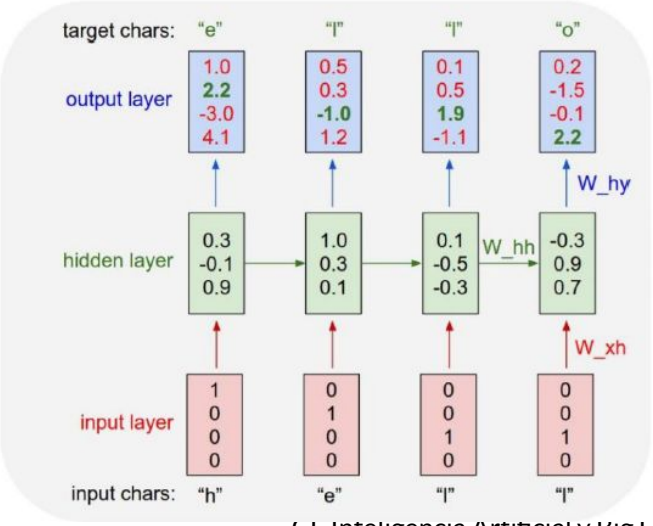

2. Modelos del lenguaje con RNNs

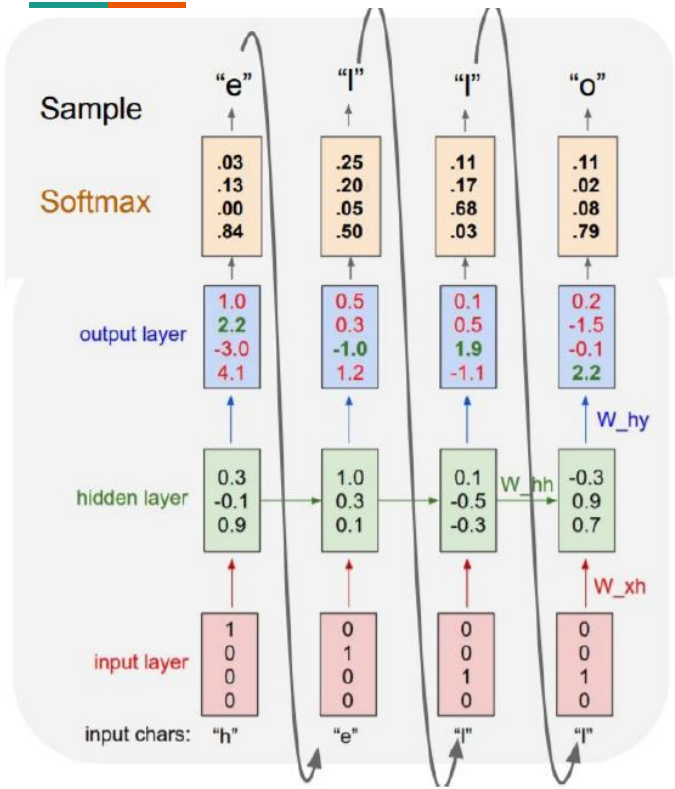

Podemos utilizar el modelo del lenguaje como un modelo generativo y utilizarlo para generar texto.

A partir de las probabilidades de la capa softmax, muestreamos el siguiente carácter a utilizar.

2. Modelos del lenguaje con RNNs

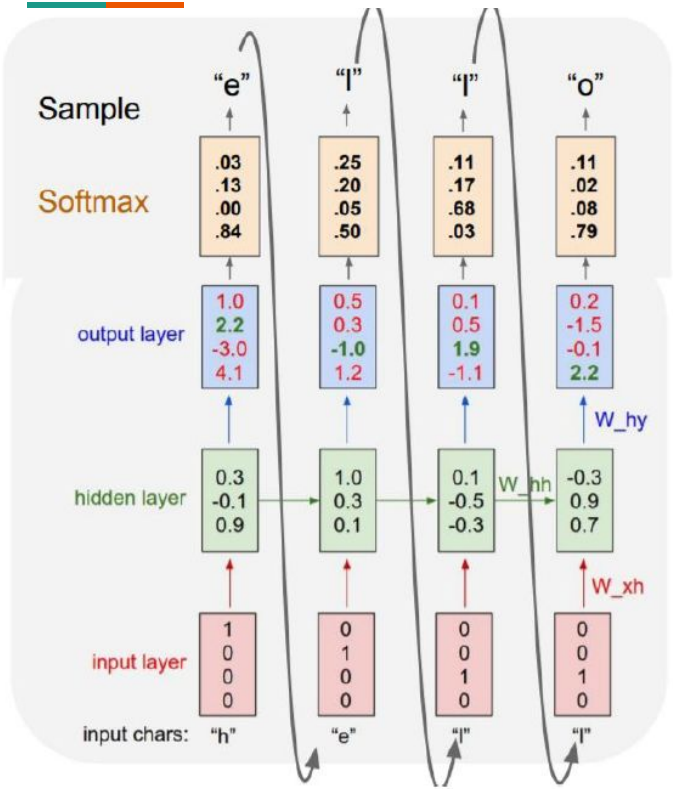

Hacer un muestreo aleatorio, en vez de sacar el carácter con la mayor probabilidad directamente, nos permite obtener resultados diferentes cada vez que usamos el modelo.

El carácter de output de cada time step se convierte en el input del siguiente.

2. Modelos del lenguaje con RNNs

```
PANDARUS:
Alas, I think he shall be come approached and the day
When little srain would be attain'd into being never fed,
And who is but a chain and subjects of his death,
I should not sleep.

Second Senator:
They are away this miseries, produced upon my soul,
Breaking and strongly should be buried, when I perish
The earth and thoughts of many states.

DUKE VINCENTIO:
Well, your wit is in the care of side and that.

Second Lord:
They would be ruled after this chamber, and
my fair nues begun out of the fact, to be conveyed,
Whose noble souls I'll have the heart of the wars.

Clown:
Come, sir, I will make did behold your worship.

VIOLA:
I'll drink it.
```

```
VIOLA:
Why, Salisbury must find his flesh and thought
That which I am not aps, not a man and in fire,
To show the reining of the raven and the wars
To grace my hand reproach within, and not a fair are hand,
That Caesar and my goodly father's world;
When I was heaven of presence and our fleets,
We spare with hours, but cut thy council I am great,
Murdered and by thy master's ready there
My power to give thee but so much as hell:
Some service in the noble bondman here,
Would show him to her wine.

KING LEAR:
O, if you were a feeble sight, the courtesy of your law,
Your sight and several breath, will wear the gods
With his heads, and my hands are wonder'd at the deeds,
So drop upon your lordship's head, and your opinion
Shall be against your honour.
```

2. Modelos del lenguaje con RNNs

```
static void do_command(struct seq_file *m, void *v)
{
  int column = 32 << (cmd[2] & 0x80);
  if (state)
    cmd = (int)(int_state ^ (in_8(&ch->ch_flags) & Cmd) ? 2 : 1);
  else
    seq = 1;
  for (i = 0; i < 16; i++) {
    if (k & (1 << 1))
      pipe = (in_use & UMXTHREAD_UNCCA) +
        ((count & 0x00000000fffffff8) & 0x000000f) << 8;
    if (count == 0)
      sub(pid, ppc_md.kexec_handle, 0x20000000);
    pipe_set_bytes(i, 0);
  }
  /* Free our user pages pointer to place camera if all dash */
  subsystem_info = &of_changes[PAGE_SIZE];
  rek_controls(offset, idx, &soffset);
  /* Now we want to deliberately put it to device */
  control_check_polarity(&context, val, 0);
  for (i = 0; i < COUNTER; i++)
    seq_puts(s, "policy ");
}
```

2. Arquitecturas LSTM y GRU

Hemos visto redes recurrentes en su variante más sencilla, la vanilla RNN. Este tipo de RNNs tiene una serie de problemas que ha llevado a la creación de nuevas arquitecturas más efectivas y fáciles de entrenar.
Dos problemas muy típicos en el entrenamiento de RNNs son los problemas de **exploding gradients** y v**anishing gradients**.

3. Arquitecturas LSTM y GRU

- Vanishing gradients: los gradientes “se desvanecen” y van a 0.
- Exploding gradients: los gradientes “explotan” y se hacen muy grandes.

Vienen del hecho de tener que hacer backpropagation sobre una secuencia larga de elementos.
Hacen que el entrenamiento se vuelva inestable o la red no entrene directamente.

3. Arquitecturas LSTM y GRU

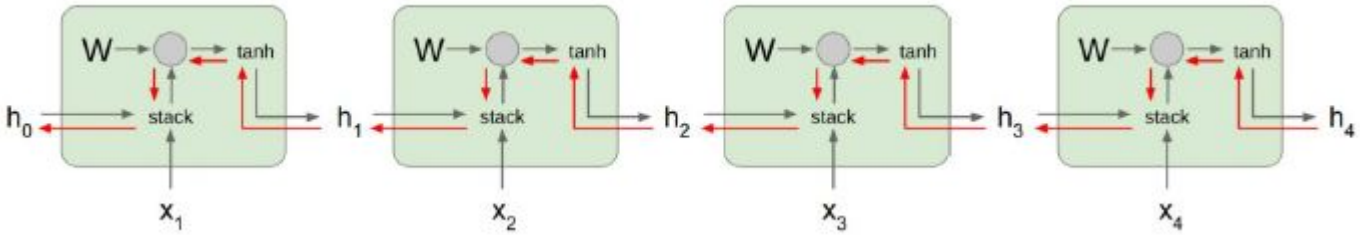

El problema viene de la multiplicación continua por los elementos de la matriz W de pesos al hacer backpropagation a través de la secuencia.

3. Arquitecturas LSTM y GRU

Intuitivamente y, de manera simplificada, el problema es similar a lo que pasa cuando multiplicamos un número por sí mismo en muchas ocasiones:

- Si es mayor que 1, obtenemos valores cada vez más grandes: exploding gradient.
- Si está entre 0 y 1, obtenemos valores más cercanos a 0: vanishing gradient.

3. Arquitecturas LSTM y GRU

Un truco práctico para solucionar exploding gradients (pero no vanishing gradients) es utilizar gradient clipping. Se mide la norma de los gradientes al hacer backpropagation en cada time step y, si es muy grande, se divide el gradiente por una constante.

3. Arquitecturas LSTM y GRU

LSTM: Long Short-Term Memory, En la práctica, las redes recurrentes simples presentan problemas para aprender relaciones entre elementos en time steps muy separados, debido a factores como los vanishing y exploding gradients.

- Estos problemas hacen que parte del potencial de las redes recurrentes se pierden.
- Las LSTM se diseñaron para solucionar este problema de “memoria” de las vanilla RNN.

3. Arquitecturas LSTM y GRU

Mantienen un estado interno adicional, el cell state (c_t), aparte del tradicional hidden state (h_t).

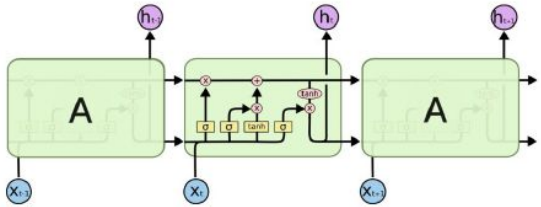

Vanilla RNN

$$h_t = \tanh\left(W\begin{pmatrix}h_{t-1}\\x_t\end{pmatrix}\right)$$

LSTM

$$\begin{pmatrix}i\\f\\o\\g\end{pmatrix} = \begin{pmatrix}\sigma\\\sigma\\\sigma\\\tanh\end{pmatrix} W\begin{pmatrix}h_{t-1}\\x_t\end{pmatrix}$$

$$c_t = f \odot c_{t-1} + i \odot g$$

$$h_t = o \odot \tanh(c_t)$$

i, **f**, **o** son vectores con valores entre 0 y 1. Actúan de "puertas"

3. Arquitecturas LSTM y GRU

Cuatro vectores distintos que nos dan los valores de c_t y de h_t: i, f, o, g.

- f se conoce como ***forget gate*** y, al ser multiplicada por c_{t-1}, nos dice cuánto tenemos que olvidar del estado anterior.
- i se conoce como ***input gate*** y representa cuánto hemos de escribir en c_t a partir de lo visto en g (sin nombre en especial)
- c_t se obtiene como una mezcla de "cuánto recordamos del pasado" ($f \cdot c_{t-1}$) y "cuánta información nueva queremos añadir" ($i \cdot g$).
- o se conoce como **output gate** y nos dice cuánto de nuestro estado interno c_t hemos de revelar en el nuevo *hidden state*.

3. Arquitecturas LSTM y GRU

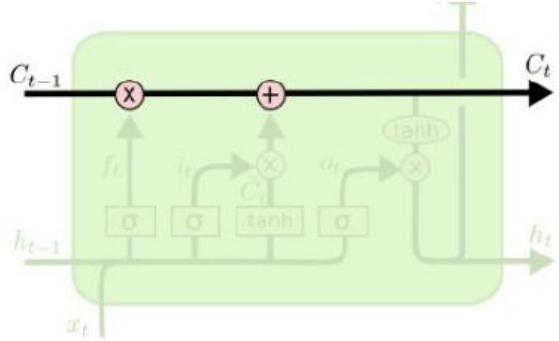

Vanilla RNN

$$h_t = \tanh\left(W\begin{pmatrix}h_{t-1}\\x_t\end{pmatrix}\right)$$

LSTM

$$\begin{pmatrix}i\\f\\o\\g\end{pmatrix} = \begin{pmatrix}\sigma\\\sigma\\\sigma\\\tanh\end{pmatrix} W\begin{pmatrix}h_{t-1}\\x_t\end{pmatrix}$$

$$c_t = f \odot c_{t-1} + i \odot g$$

$$h_t = o \odot \tanh(c_t)$$

Las LSTM no sufren de vanishing o exploding gradients.
La solución a estos problemas viene del estado interno ct, que crea una especie de “autopista de la información” que ayuda durante backpropagation.

3. Arquitecturas LSTM y GRU

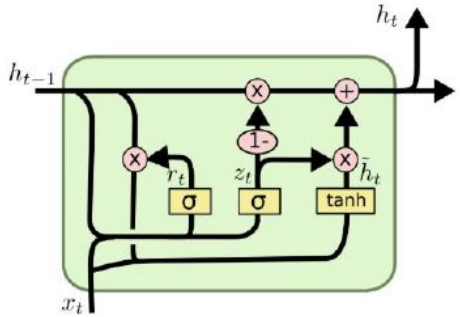

$$r_t = \sigma(W_{xr}x_t + W_{hr}h_{t-1} + b_r)$$
$$z_t = \sigma(W_{xz}x_t + W_{hz}h_{t-1} + b_z)$$
$$\tilde{h}_t = \tanh(W_{xh}x_t + W_{hh}(r_t \odot h_{t-1}) + b_h)$$
$$h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \tilde{h}_t$$

GRU: Tiene un sistema similar de gates al visto en la LSTM. Combina el cell state y el hidden state en un solo elemento.

3. Arquitecturas LSTM y GRU

Es común apilar RNNs (stacked RNNs). La salida de una RNN se utiliza como la entrada secuencial de la RNN apilada encima de ella.
También es común utilizar RNNs bidireccionales donde las secuencias de entrada se leen de atrás hacia adelante y de delante hacia atrás.

3. Arquitecturas LSTM y GRU

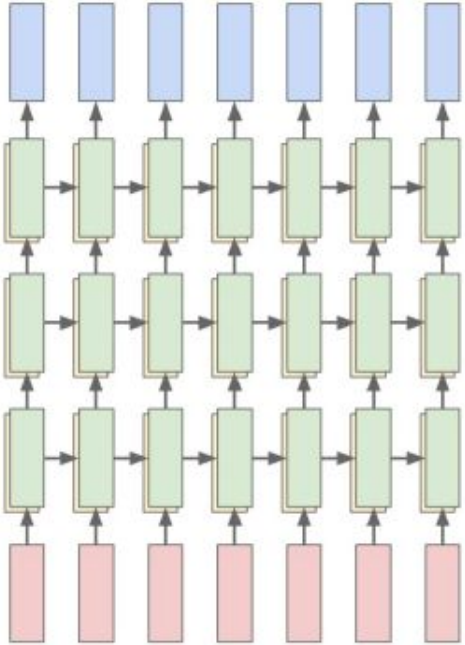

Fuente de la imagen: Stanford CS231N